

Hyperspherical Variational Auto-Encoders

Reproduction & Analyse Critique

Mouhssine Rifaki Raphaël Rubrice

Master MVA - Computational Statistics

7 janvier 2026

Rappel : Auto-Encodeurs Variationnels

Objectif VAE : Maximiser l'ELBO

$$\mathcal{L}(\phi, \psi) = \underbrace{\mathbb{E}_{q_\psi(z|x)}[\log p_\phi(x|z)]}_{\text{Reconstruction}} - \underbrace{\text{KL}(q_\psi(z|x)\|p(z))}_{\text{Régularisation}}$$

Choix standard :

- Prior : $p(z) = \mathcal{N}(0, I)$
- Postérieur : $q_\psi(z|x) = \mathcal{N}(\mu(x), \sigma^2(x)I)$

Reparamétrisation : $z = \mu + \sigma \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$

Problèmes du Prior Gaussien

Basses dimensions : Gravité vers l'origine

- Prior gaussien attire tous les points vers 0.
- Empêche la séparation naturelle des clusters.

Hautes dimensions : Effet bulle de savon

- Masse concentrée sur une coquille sphérique.
- Distance euclidienne perd son sens.

Distribution de Von Mises-Fisher

Définition : Distribution sur l'hypersphère $S^{m-1} \subset \mathbb{R}^m$

$$q(z|\mu, \kappa) = C_m(\kappa) \exp(\kappa \mu^\top z), \quad \|z\|_2 = 1$$

où $C_m(\kappa) = \frac{\kappa^{m/2-1}}{(2\pi)^{m/2} I_{m/2-1}(\kappa)}$

Paramètres :

- $\mu \in S^{m-1}$: Direction moyenne
- $\kappa \geq 0$: Concentration ($\kappa = 0 \Rightarrow$ Uniforme)

Avantages : Prior uniforme (pas d'attraction origine), κ appris par échantillon.

Inconvénients : $C_m(\kappa)$ implique la fonction de Bessel (instabilité), Nouvelle reparamétrisation préservant les gradients à définir.

Divergence KL & Échantillonnage

Divergence KL :


$$\text{KL}(\text{vMF}(\mu, \kappa) \| \mathcal{U}(S^{m-1})) = \kappa \frac{I_{m/2}(\kappa)}{I_{m/2-1}(\kappa)} + \log C_m(\kappa) + \text{cst}$$

Échantillonnage (Ulrich 1984) :


- ➊ Échantillonner $\omega \sim g(\omega | \kappa, m)$ par acceptation-rejet (1D)
- ➋ Échantillonner $v \sim \mathcal{U}(S^{m-2})$
- ➌ Construire $z' = (\omega, \sqrt{1 - \omega^2} v^\top)^\top$
- ➍ Transformation de Householder : $z = U(\mu)z'$

Rejet en 1D seulement \Rightarrow pas de malédiction de la dimensionnalité


Exp. 1 : Reconstruction de 3 vMF sur sur S^1 , plongé dans \mathbb{R}^{100}




Données originales



\mathcal{S} -VAE : préservé



\mathcal{N} -VAE ($\beta_{KL}=0.1$) :
déformé

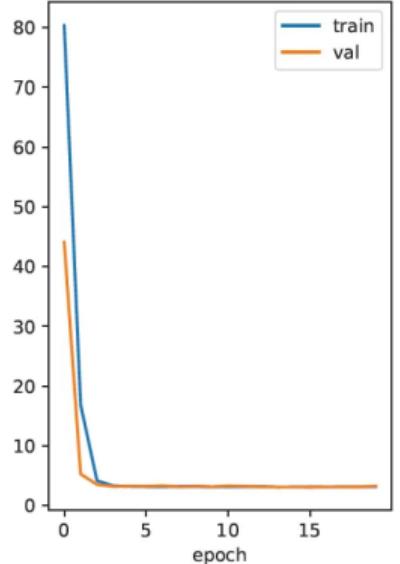


\mathcal{N} -VAE ($\beta_{KL}=1$) :
davantage déformé

Modèle	Train LL	Val LL
\mathcal{S} -VAE	-94.82	-94.85
\mathcal{N} -VAE ($\beta_{KL}=0.1$)	-107.73	-107.82
\mathcal{N} -VAE ($\beta_{KL}=1$)	-97.94	-97.97


Exp. 1 : Courbes d'Apprentissage

S-VAE training & validation loss
Train LL: -94.8237, Val LL: -94.8456




\mathcal{S} -VAE : convergence rapide

N-VAE training & validation loss
Train LL: -107.7333, Val LL: -107.8241



\mathcal{N} -VAE : convergence lente ($\beta_{KL}=0.1$)

N-VAE training & validation loss
Train LL: -97.9366, Val LL: -97.9718



\mathcal{N} -VAE : convergence lente ($\beta_{KL}=1$)

\mathcal{S} -VAE récupère la structure circulaire avec +13 nats de log-vraisemblance

Exp. 2 : Évaluation Non-Supervisée sur MNIST (Table 1)

Métriques : LL (IWAE, 500 samples), $\mathcal{L}[q]$ (ELBO), RE (Reconstruction), KL

Protocole : 10 runs, early stopping (patience=50), warmup 100 epochs.

d	\mathcal{N} -VAE				\mathcal{S} -VAE			
	LL	$\mathcal{L}[q]$	RE	KL	LL	$\mathcal{L}[q]$	RE	KL
2	-135.73±.83	-137.08±.83	-129.84±.91	7.24±.11	-132.50±.73	-133.72±.85	-126.43±.91	7.28±.14
5	-110.21±.21	-112.98±.21	-100.16±.22	12.82±.11	-108.43±.09	-111.19±.08	-97.84±.13	13.35±.06
10	-93.84±.30	-98.36±.30	-78.93±.30	19.44±.14	-93.16±.31	-97.70±.32	-77.03±.39	20.67±.08
20	-88.90±.26	-94.79±.19	-71.29±.45	23.50±.31	-89.02±.31	-96.15±.32	-67.65±.43	28.50±.22
40	-88.93±.30	-94.91±.18	-71.14±.56	23.77±.49	-90.87±.34	-101.26±.33	-67.75±.70	33.50±.45

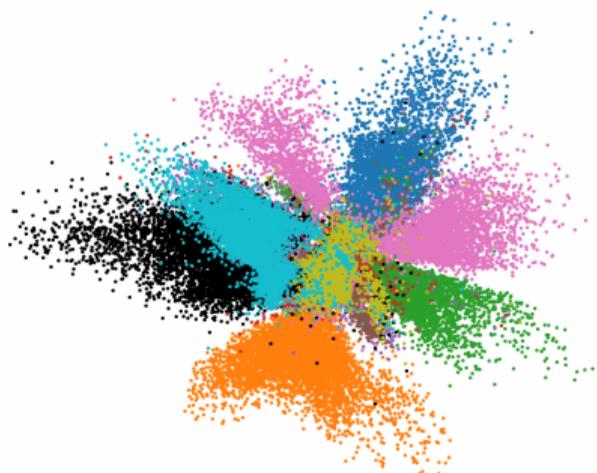
Observations

- $d \leq 10$: \mathcal{S} -VAE meilleur en LL
- $d \geq 20$: \mathcal{N} -VAE rattrape (+ de params)
- RE : \mathcal{S} -VAE **toujours** meilleur


Interprétation

Prior uniforme \Rightarrow pas de "gravité origine"
 \Rightarrow meilleure utilisation de l'espace latent
 \Rightarrow reconstruction plus fidèle

Exp. 3 : Visualisation du dataset MNIST



N-VAE: Espace latent dans \mathbb{R}^2



\mathcal{S} -VAE: Espace latent dans \mathcal{S}^2 (projection de Hammer)

Les classes superposées dans l'espace latent du \mathcal{N} -VAE sont mieux séparées dans celui du \mathcal{S} -VAE (cohérent avec le papier).

Exp. 4 : Classification Semi-Supervisée (M1)

Protocole : K-NN sur l'espace latent (MNIST, 5 runs, 10% du train set).

Les valeurs indiquent l'accuracy (%). * : différence significative ($p < 0.01$).

Dim (d)	100 Labels		600 Labels		1000 Labels	
	\mathcal{N} -VAE	\mathcal{S} -VAE	\mathcal{N} -VAE	\mathcal{S} -VAE	\mathcal{N} -VAE	\mathcal{S} -VAE
2	57.2 ± 3.6	50.8 ± 4.9	57.7 ± 2.7	47.6 ± 6.2	56.1 ± 1.7	41.4 ± 12.8
5	71.8* ± 2.1	66.9 ± 1.3	79.9 ± 1.6	77.4 ± 1.3	80.2* ± 0.9	78.4 ± 0.7
10	70.3 ± 2.2	72.0 ± 1.6	83.7 ± 0.7	84.9 ± 0.3	86.7 ± 1.3	86.4 ± 0.5
20	66.9 ± 2.5	69.0 ± 1.3	85.4 ± 0.3	87.2* ± 0.5	87.7 ± 0.6	89.3* ± 0.4
40	65.8 ± 0.9	69.7* ± 2.0	83.1 ± 0.4	87.4* ± 0.4	85.7 ± 0.5	89.0* ± 0.4

- $d \leq 5$: \mathcal{N} -VAE meilleur (contraire au papier)
- $10 \leq d \leq 20$: \mathcal{S} -VAE avantage clair (cohérent avec papier)
- $d > 20$: \mathcal{S} -VAE avantage clair (contraire au papier)

Comparaison M1 : Résultats Originaux vs Reproduction

Table 2 du Papier (Davidson et al.)
(Entrainement sur 100% MNIST vs 10% pour nous)

Dim (d)	100 Labels		600 Labels		1000 Labels	
	\mathcal{N} -VAE	\mathcal{S} -VAE	\mathcal{N} -VAE	\mathcal{S} -VAE	\mathcal{N} -VAE	\mathcal{S} -VAE
2	72.6	77.9*	80.8	84.9*	81.7	85.6*
5	81.8	87.5*	90.9	92.8*	92.0	93.4*
10	75.7	80.6*	88.4	91.2*	90.2	92.8*
20	71.3	72.8*	88.3	89.1*	90.1	91.1*
40	72.3*	67.7	88.0	87.4	90.3	90.4

Divergences Méthodologiques

- **Données** : 60k (Eux) vs 6k (Nous).
- **Robustesse** : 20 runs (Eux) vs 5 runs (Nous).

Analyse de la Reproduction

- **Validé** : \mathcal{S} -VAE domine sur $10 \leq d \leq 20$.
- **Different** : Nos résultats favorisent \mathcal{S} -VAE à $d = 40$.
Hypothèse: Moins d'overfitting du \mathcal{S} -VAE sur petit dataset ?

Exp. 5 : Classification Semi-Supervisée (Architecture M1+M2)

Comparaison des configurations Latent (z_1) + Latent (z_2).

Dimensions		Configuration Modèle		
z_1	z_2	$\mathcal{N} + \mathcal{N}$	$\mathcal{S} + \mathcal{S}$	$\mathcal{S} + \mathcal{N}$
5	5	61.5*	63.0*	65.3*
5	10	60.9	62.7	66.1*
5	50	62.5	62.4	66.6*
10	5	66.9*	70.1*	70.9*
10	10	68.7*	70.6*	71.3*
10	50	69.4*	70.3*	69.7
50	5	69.9	73.3*	73.4*
50	10	68.7	72.7*	73.1*
50	50	76.3*	71.9*	74.0*

Tendances Observées

- Performance \propto Dimension de z_1 .
- Optimum atteint pour $z_1 = 50$ (comme dans le papier).

Stratégie $\mathcal{S} + \mathcal{N}$

L'hybridation est la stratégie la plus robuste (Meilleur score ou équivalent dans **8/9** cas).

Comparaison avec Résultats Originaux

Papier (Table 3) :

Latent Dimensions		Model Configuration		
Dim (z1)	Dim (z2)	$\mathcal{N} + \mathcal{N}$	$\mathcal{S} + \mathcal{S}$	$\mathcal{S} + \mathcal{N}$
5	5	90.0	94.0*	93.8
5	10	90.7	94.1	94.8*
5	50	90.7	92.7	93.0*
10	5	90.7	91.7	94.0*
10	10	92.2	96.0*	95.9*
10	50	92.9	95.1	95.7*
50	5	92.0	91.7	95.8*
50	10	93.0	95.8	97.1*
50	50	93.2	94.2	97.4*

Écarts :

- Même que précédemment

Conclusion :

- Nos résultats confirment que $\mathcal{S} + \mathcal{N}$ est le plus intéressant (Meilleur ou comparable partout)
- Reproduction complète infaisable (coût computationnel)

Analyse des Divergences avec la Référence

1. Volume de Données (Facteur Dominant)

Passage de 60k (Papier) à 6k (Nous) images \Rightarrow Baisse mécanique de la généralisation (10-15%).

2. Stabilité Statistique

5 runs vs 20 runs. La variance d'initialisation devient importante sur les petits datasets \Rightarrow écarts moins significatifs.

3. Convergence de κ

Le paramètre de concentration κ converge plus lentement en haute dimension, potentiel sous-apprentissage.

Ce qui est Nouveau

Contributions :

- ➊ κ appris (vs fixé dans Guu et al. 2018)
- ➋ Extension reparamétrisation par rejet (Lemme 2)
- ➌ Prior uniforme sur hypersphère

Points intéressants :

- Design espace latent conscient de la géométrie
- Meilleure séparabilité des clusters en basse dim.
- Adapté aux données directionnelles
- Amélioration prédiction de liens (graphes)

Limitations

Faiblesses :

- Collapse haute dimension : Difficulté d'estimation lorsque $\kappa \gg d$, aire $S(m-1) \rightarrow 0$ quand $m \rightarrow \infty$
- vMF moins expressif (1 param κ) que gaussienne diagonale
- Coût et stabilité : gradients des fonctions de Bessel, échantillonnage par rejet

Manquant :

- Pas de comparaison avec β -VAE
- Pas d'analyse théorique de quand \mathcal{S} -VAE est meilleur
- Manque de discussion plus poussée sur l'implémentation stable de \mathcal{S} -VAE (κ grand, contraintes sur le modèle)

Difficultés reproduction :

- $\sim 1\text{h/run}$ (training set complet) \times 10-20 runs \times configs

Bilan

Papier :

- VAE hypersphérique avec distribution vMF
- κ appris, avantages en basse dimension

Notre reproduction :

- Récupération variété circulaire : OK
- Table 1 (évaluation non-supervisée) : OK
- Tendances M1 pour $d \geq 10$: OK
- Valeurs absolues : différentes (contraintes calcul)

Leçon : La géométrie de l'espace latent compte.

Pour aller plus loin

Papier

Davidson et al., *Hyperspherical Variational Auto-Encoders*
arxiv.org/abs/1804.00891

Code

github.com/blackswan-advitamaeternam/HVAE